

统计(机器)学习 Homework - 9

1. 设 $X = (X_1, \dots, X_m)^\top$ 是 m 维随机变量, 协方差矩阵为 $\text{cov}(X) \stackrel{\text{def}}{=} \Sigma$. 设矩阵 Σ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$; 这 m 个特征值对应的单位特征向量为 $\alpha_1, \dots, \alpha_m$ (特征向量矩阵为 $(\alpha_1, \alpha_2, \dots, \alpha_m) \in \mathbb{R}^{m \times m}$, 其中 $\alpha_k = (\alpha_{k1}, \alpha_{k2}, \dots, \alpha_{km})^\top$ 为列向量), 若用 Y_k 表示 X 的第 k 个主成分, 且 $Y = (Y_1, \dots, Y_m)^\top$, 证明:

(1) $\text{cov}(Y) = \text{diag}(\lambda_1, \dots, \lambda_m)$;

证: 记特征向量矩阵为 $A = (\alpha_1, \dots, \alpha_m)$, 且满足:

$$\Sigma = A \cdot \Lambda \cdot A^\top = A \cdot \Lambda \cdot A^\top \Leftrightarrow A^\top \cdot \Sigma \cdot A = \Lambda$$

$A \cdot \Lambda \cdot A^\top$ 为 Σ 的谱分解, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$

其中 $\lambda_1, \dots, \lambda_m$ 为 Σ 的特征值

注意到 $Y = A^\top \cdot X$

$$\Rightarrow \text{cov}(Y) = A^\top \cdot \text{cov}(X) \cdot A$$

$$= A^\top \cdot \Sigma \cdot A$$

$$= \Lambda$$

$$= \text{diag}(\lambda_1, \dots, \lambda_m)$$

(2) $\sum_i \lambda_i = \sum_i \Sigma_{ii} (\Sigma_{ii} = \text{var}(X_i)).$

证: 注意到 $\sum_i \Sigma_{ii} = \text{trace}(\Sigma)$

trace 具有可交换性: $\text{trace}(MN) = \text{trace}(NM)$

则有:

$$\text{trace}(\Sigma) = \text{trace}(A \Lambda A^\top)$$

$$= \text{trace}(A^\top A \Lambda)$$

$$= \text{trace}(A^\top \cdot A \cdot \Lambda)$$

$$= \text{trace}(\Lambda)$$

$$= \sum_{i=1}^m \lambda_i$$

(3) 因子负荷量为

$$\rho(Y_k, X_i) = \text{cor}(Y_k, X_i) = \frac{\sqrt{\lambda_k} \alpha_{ki}}{\sqrt{\Sigma_{ii}}}$$

$$\text{证: } Y_k = \alpha_k^T \cdot X = \sum_{j=1}^n \alpha_{kj} X_j$$

$$\text{Cov}(Y_k, X_i) = \text{Cov}\left(\sum_{j=1}^n \alpha_{kj} X_j, X_i\right)$$

$$= \sum_{j=1}^n \alpha_{kj} \cdot \text{Cov}(X_j, X_i)$$

$$\text{记 } \Sigma \text{ 的第 } i \text{ 列为 } \Sigma_i, \text{ 则有 } \Sigma_i = (\text{Cov}(X_1, X_i), \dots, \text{Cov}(X_m, X_i))^T$$

$$\begin{aligned} \Rightarrow \text{Cov}(Y_k, X_i) &= \alpha_k^T \cdot \Sigma_i \\ &= (\alpha_k^T \cdot \Sigma)_i \\ &= \lambda_k \cdot \alpha_{ki} \end{aligned}$$

另一方面:

$$\begin{aligned} \text{Var}(Y_k) &= \text{Var}(\alpha_k^T X) \\ &= \alpha_k^T \cdot \text{Cov}(X) \cdot \alpha_k \\ &= \alpha_k^T \cdot \Sigma \cdot \alpha_k \\ &= \lambda_k \end{aligned}$$

则有:

$$\begin{aligned} \rho(Y_k, X_i) &= \text{Cor}(Y_k, X_i) \\ &= \frac{\text{Cov}(Y_k, X_i)}{\sqrt{\text{Var}(Y_k)} \sqrt{\text{Var}(X_i)}} \end{aligned}$$

$$= \frac{\lambda_k \cdot \alpha_{ki}}{\sqrt{\lambda_k} \sqrt{\Sigma_{ii}}}$$

$$= \frac{\sqrt{\lambda_k} \cdot \alpha_{ki}}{\sqrt{\Sigma_{ii}}}$$

$$(4) \sum_{i=1}^m \Sigma_{ii} \rho(Y_k, X_i)^2 = \lambda_k$$

证: 由上题可知 $\rho(Y_k, X_i)^2 = \frac{\lambda_k \alpha_{ki}^2}{\Sigma_{ii}}$

则有:

$$\sum_{i=1}^m \Sigma_{ii} \rho(Y_k, X_i)^2$$

$$= \sum_{i=1}^m \Sigma_{ii} \cdot \frac{\lambda_k \alpha_{ki}^2}{\Sigma_{ii}}$$

$$= \lambda_k \cdot \sum_{i=1}^m \alpha_{ki}^2$$

由于 α_k 是单位特征向量, $\sum_{i=1}^m \alpha_{ki}^2 = \|\alpha_k\|^2 = 1$

则有 $\sum_{i=1}^m \Sigma_{ii} \rho(Y_k, X_i)^2 = \lambda_k$

$$(5) \sum_k \rho^2(Y_k, X_i) = 1$$

证: 注意到对于 Σ 有如下谱分解:

$$\Sigma = A \cdot \Lambda \cdot A^T = A \cdot \Lambda \cdot A^T$$

$$\text{其中 } \Lambda = \text{diag}(\lambda_1, \dots, \lambda_m), A = (\alpha_1, \dots, \alpha_m)$$

注意到等式右侧:

$$(A \cdot \Lambda \cdot A^T)_{ij} = \sum_{k=1}^m \alpha_{ki} \cdot \lambda_k \cdot \alpha_{kj}$$

等式两端的 (i, i) 处的元素满足:

$$\Sigma_{ii} = \sum_{k=1}^m \alpha_{ki} \cdot \lambda_k \cdot \alpha_{ki} = \sum_{k=1}^m \lambda_k \alpha_{ki}^2$$

$$\Rightarrow \sum_{k=1}^m \frac{\lambda_k \cdot \alpha_{ki}^2}{\Sigma_{ii}} = 1$$

$$\Rightarrow \sum_{k=1}^m \rho(Y_k, X_i) = 1$$

□

2. 给定标准化样本矩阵 $\mathbf{X} \in \mathbb{R}^{N \times p}$, \mathbf{X} 的 SVD 分解为 $\mathbf{X} = \mathbf{U} \Sigma \mathbf{V}^T$, 其中 $\mathbf{U} \in \mathbb{R}^{N \times p}$ 是左特征向量矩阵, $\Sigma = \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_p\} \in \mathbb{R}^{p \times p}$, 其中 $\sigma_1 \geq \dots \geq \sigma_p$, $\mathbf{V} \in \mathbb{R}^{p \times p}$ 是右特征向量矩阵. 对 \mathbf{X} 进行主成分分析, 假设保留前 k 个主成分, $\text{rank}(\mathbf{X}) > k$. 试证明:

(1) 前 k 个样本主成分 可以表示为

$$\mathbf{Z}^{(k)} = \mathbf{U}^{(k)} \Sigma^{(k)} \in \mathbb{R}^{N \times k},$$

其中, $\mathbf{U}^{(k)}$ 是 \mathbf{U} 的前 k 列, $\Sigma^{(k)}$ 是 Σ 的前 $k \times k$ 矩阵;

$$\boxed{\mathbf{X}} = \boxed{\mathbf{U}} \boxed{\Sigma} \boxed{\mathbf{V}^T}$$

证: 对于标准化样本矩阵, 每一维度上的样本方差均满足 $\Sigma_{ii} = 1$

即其样本协方差矩阵 S 的对角线为 1, 且样本相关系数满足:

$$\begin{aligned}
 R &= \text{diag}(S)^{-1/2} \cdot S \cdot \text{diag}(S)^{-1/2} \\
 &= S \\
 &= \frac{1}{n-1} \cdot X^T \cdot X \\
 &= \frac{1}{n-1} V \Sigma U^T U \Sigma V^T \\
 &= \frac{1}{n-1} \cdot V \cdot \Sigma^2 \cdot V^T
 \end{aligned}$$

设 R 的特征值为 $\lambda_1, \dots, \lambda_p$, 满足 $\lambda_k = \frac{\sigma_k^2}{n-1}$
 对应特征向量为 V_k , 为 V 的第 k 列

根据样本主成分的定义, 前 k 个样本主成分可表示为:

$$Z^{(k)} = X \cdot V^{(k)}$$

$$\text{其中 } V^{(k)} = (V_1, \dots, V_k)$$

$$\text{也即 } Z^{(k)} = U \Sigma V^T \cdot V^{(k)}$$

$$= U \cdot \Sigma \begin{bmatrix} I_k \\ 0_{p-k} \end{bmatrix}$$

$$= U \cdot \begin{bmatrix} \Sigma^{(k)} \\ 0_{p-k} \end{bmatrix}$$

$$= [U^{(k)}, U^{(p-k)}] \cdot \begin{bmatrix} \Sigma^{(k)} \\ 0_{p-k} \end{bmatrix}$$

$$= U^{(k)} \cdot \Sigma^{(k)}$$

(2) 试证明下面问题的解为 $B = V^{(k)T}$ (其中 $V^{(k)}$ 是 V 的前 k 列):

$$B = \arg\min_B \|X - Z^{(k)} B\|_F^2.$$

$$\text{证: } \min_B \|X - Z^{(k)} B\|_F^2 \Leftrightarrow \sum_{i=1}^p \min_{b_i} \|x_i - Z^{(k)} b_i\|_2^2$$

其中 X_i 是 X 的第 i 列, b_i 是 B 的第 i 列

则由最小二乘法: $b_i = (\mathbf{Z}^{(k)T} \mathbf{Z}^{(k)})^{-1} \mathbf{Z}^{(k)T} X_i$

$$\Rightarrow B = (\mathbf{Z}^{(k)T} \mathbf{Z}^{(k)})^{-1} \mathbf{Z}^{(k)T} X$$

注意到 $X = U \Sigma V^T$, $\mathbf{Z}^{(k)} = U^{(k)} \Sigma^{(k)}$

则有:

$$B = (\Sigma^{(k)^2})^{-1} \cdot \Sigma^{(k)} U^{(k)T} U \Sigma V^T$$

$$= (\Sigma^{(k)})^{-1} \cdot [I_k, 0_{p-k}] \cdot \Sigma V^T$$

$$= (I_k, 0_{p-k}) \cdot V^T$$

$$= V^{(k)T}$$

(3) 证明以下最优化问题的解为 $\mathbf{X}^{(k)} = \mathbf{U}^{(k)} \Sigma^{(k)} \mathbf{V}^{(k)T}$:

$$\min_{\mathbf{L}} \|\mathbf{X} - \mathbf{L}\|_F, \quad \text{s.t.} \quad \text{rank}(\mathbf{L}) \leq k.$$

(提示: 对于任意矩阵 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n} (n \leq m)$, 有 $\sigma_{i+j-1}(\mathbf{A} + \mathbf{B}) \leq \sigma_i(\mathbf{A}) + \sigma_j(\mathbf{B})$,

其中, $1 \leq i, j \leq n, i+j-1 \leq n$)

证: 由于 $\text{rank}(L) \leq k$, 则当 $j > k$ 时, 有 $\sigma_j(L) = 0$

$$\sigma_{i+j-1}(X) \leq \sigma_i(X-L) + \sigma_j(L)$$

$$\Rightarrow \sigma_{i+j}(X) \leq \sigma_i(X-L) + \sigma_{j+1}(L)$$

$$j \geq k \text{ 时: } \sigma_{i+j}(x) \leq \sigma_i(x-L)$$

$$\|x-L\|_F^2 = \sum_{i=1}^p \sigma_i^2(x-L)$$

$$\geq \sum_{i=1}^{p-k} \sigma_i^2(x-L)$$

$$\geq \sum_{i=1}^{p-k} \sigma_{i+k}^2(x)$$

$$= \sum_{i=k+1}^p \sigma_i^2(x)$$

$$\text{也即 } \|x-L\|_F \geq \left(\sum_{i=k+1}^p \sigma_i^2(x) \right)^{1/2}$$

注意到 $\|\cdot\|_F$ 有正交不变性

设 $\hat{U} = (U, U_\perp)$, 其中 U_\perp 是 U 的正交补空间的一组正交基

$$\text{并且有 } \hat{U} \hat{U}^T = I, \quad \hat{U}^T \cdot U = \begin{bmatrix} I_p \\ 0 \end{bmatrix}, \quad \hat{U}^T U^{(k)} = \begin{bmatrix} I_k \\ 0 \end{bmatrix}$$

则当 $L = X^{(k)} = U^{(k)} \cdot \Sigma^{(k)} \cdot V^{(k)T}$ 时:

$$\|x-L\|_F = \|U \Sigma V^T - U^{(k)} \Sigma^{(k)} V^{(k)T}\|_F$$

$$= \|U \Sigma V^T - U \begin{pmatrix} \Sigma^{(k)} \\ 0_{p-k} \end{pmatrix} V^T\|_F$$

$$= \| \hat{U}^T U \Sigma V^T V - \hat{U}^T U \begin{pmatrix} \Sigma^{(k)} \\ 0_{p-k} \end{pmatrix} V^T V \|_F$$

$$= \left\| \begin{bmatrix} I_p \\ 0_{n-p} \end{bmatrix} \cdot (\Sigma - \begin{pmatrix} \Sigma^{(k)} \\ 0_{p-k} \end{pmatrix}) \right\|_F$$

$$= \left(\sum_{i=k+1}^p \sigma_i^2(x) \right)^{1/2}$$

也即 $L = U^{(k)} \Sigma^{(k)} V^{(k)T}$ 时, $\|X - L\|_F$ 恰好取到下界

$$\text{即有 } \min_L \|X - L\|_F = \left(\sum_{i=k+1}^p \sigma_i^2(x) \right)^{1/2}$$

且 $L = U^{(k)} \Sigma^{(k)} V^{(k)T}$ 是最优化问题的一个解 □